
Алгоритм декомпозиции
периодических колебаний :
пульс, дыхание, случайные движения

Постановка задачи

- Подается многомерной нестационарной временной рсг:
 $X(t) = (A_x(t), A_y(t), A_z(t), \Phi_x(t), \Phi_y(t), \Phi_z(t))$ - 6 каналов
- С физической точки зрения: $X(t) = \underbrace{S_{\text{допх}}(t) + S_{\text{шумк}}(t)}_{\text{нежелательное влияние}} + N_{\text{звук}}(t) + N_{\text{шум}}(t)$
- Ключевые трудности:
 - Ближние спектральные компоненты - нужно корректно различать
 - Нестационарность - амплитуда и частота могут меняться
 - Корректная обработка коррелированных данных с 6 каналов.
- Цель исследования: сравнить эффективность трёх методов
 - Линейная фильтрация
 - Вейвлет анализ
 - Нейросетевые модели

1. Линейная Филтрация полос

- Преобразование Фурье: $X(\omega) = \int_{-\infty}^{\infty} x(t) e^{-i\omega t} dt$
- Полосовой фильтр Баттерворта: $H_B(\omega) = \frac{1}{\sqrt{1 + \left(\frac{\omega^2 - \omega_0^2}{\omega \Delta\omega}\right)^{2n}}}$
- Разделение по спектрам: $X_{filt}(\omega) = X(\omega) H_B(\omega)$
- Обратное преобразование Фурье: $x_{comp}(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} X_{filt}(\omega) e^{i\omega t} d\omega$

ω_0 - центр. частота
полосы
 $\Delta\omega$ - ширина полосы
 n - порядок фильтра

Для входных:

$$f_{min} = 0,1 \text{ Гц}$$

$$f_{max} = 0,5 \text{ Гц}$$

$$\Delta f = 0,4 \text{ Гц}$$

$$f_0 = 0,22 \text{ Гц}$$

Для срезов:

$$f_{min} = 0,8 \text{ Гц}$$

$$f_{max} = 2,0 \text{ Гц}$$

$$\Delta f = 1,2 \text{ Гц}$$

$$f_0 = 1,26 \text{ Гц}$$

$\oplus$: • сложность $O(n \log n)$
• четкие частотные границы

$\ominus$: • ломается в случае нестационарности
• не удовлетворяет индивидуальности
имеет фикс. границы частот

Вейвлет-АНАЛИЗ

- Вейвлет-преобразование: $W_k(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \psi^*\left(\frac{t-b}{a}\right) dt$

$$\psi(t) = e^{-t^2/2} e^{i\omega_0 t}$$

a - параметр масштаба
 b - параметр сдвига

- Обратное преобразование: $x(t) = \frac{1}{C_\psi} \int_0^\infty \int_{-\infty}^\infty W_k(a, b) \psi_{a,b}(t) \frac{da db}{a^2}$,

$$\text{где } C_\psi = \int_0^\infty \frac{\psi^2(\omega)}{\omega} d\omega < +\infty$$

! В дискретном случае исходный сигнал делим по частотам, затем берем порождающие коэф. и делаем обр. преобразование. Выбираем уровни декомпозиции ~ 10 , выбираем порождающие группы частот.

$$\Phi_{j,k}[n] = 2^{-j/2} \Phi(2^{-j}n - k)$$

j - уровни декомпозиции, k - сдвиг, $2^{j/2}$ - нормировка

$$\Psi_{j,k}[n] = 2^{-j/2} \Psi(2^{-j}n - k)$$

n - временной индекс

$$x[n] = \sum_k \underbrace{a_{j,k}}_{\text{по низк. ф.}} \Phi_{j,k}[n] + \sum_{j=1}^J \sum_k \underbrace{d_{j,k}}_{\text{по высок. ф.}} \Psi_{j,k}[n]$$

J - макс. ур. декомпозиции

по низк. ф.
грубая аппроксимация

по высок. ф.
детализация

• Прямое преобразование: $a_{j+1}[k] = \sum_m \overset{\text{фильтр} - \text{его коэфф. используем.}}{h[m-2k]} a_j[m]$
 $d_{j+1}[k] = \sum_m \overset{\text{фильтр}}{g[m-2k]} a_j[m]$

• Обратное преобразование: $a_j[n] = \sum_k h[n-2k] a_{j+1}[k] + \sum_k g[n-2k] d_{j+1}[k]$

• Требуем энерг. сохран. : $\|x[n]\|^2 = \sum_k |a_{j,k}|^2 + \sum_{j=1}^J \sum_k |d_{j,k}|^2$

(+) Корректно работает с нестационарностями, т.к. имеет возможность отслеживать во времени изменения ~~сигнала~~ и локализовать их $\Rightarrow$ локальные изменения не влияют на не имеющие к этому отношения измерения.

(-) Сложность $O(N^2)$

Требует предварительного выбора оптимальных параметров.

Нейросетевой подход

Нейросеть можно обучать работать непосредственно на входных данных $\Rightarrow$ не требуется предварительного знания фильтров.

! Сигнальный сигнал $\rightarrow$ Encoder $\rightarrow$ Latent space $\rightarrow$ Decoder (у каждого свой)

- Временные свертки (ТСВ) — для лок. врем. паттернов
Для поиска требуется фиксированное измерение, для поиска — короткое $\Rightarrow$ разное размера ядер
- Механизм Attention — взвешивает значимость разных частей сигнала и учится игнорировать резкие движения
- Encoder — извлекает признаки разных масштабов
- Decoder — преобр. latent space $\rightarrow$ конкретную компоненту
- Latent space — содержит старые признаки компонент и взаимосвязи, а также временные контексты
- Loss-функция потерь помогает контролировать качество модели

$$\text{Loss} = \alpha \text{MSE}(\hat{f}_{\text{gox}}(\text{пер.}), f_{\text{gox}}(\text{исп.})) + \beta \text{MSE}(\hat{f}_{\text{nylbc}}(\text{пер.}), f_{\text{nylbc}}(\text{исп.}))$$

- ⊕ • Признаки в результате автоматического обучения
- Угол взаимных компонент друг на друга
- Угнорирование резких изменений и шума
- Гарантируется отсутствие индивидуальной особенности.


! В рамках эксперимента Encoder будет обрабатывать крупные и средние врем. паттерны, переходя данные в скрытое 64-мерное представление с признаками

Декодер будет восстанавливать значение и частоту колебаний


В одну эпоху обучения:

- 1) прямой проход
- 2) вычисление ошибки
- 3) определение весов
- 4) обратный проход
- 5) обновление весов.










Эксперимент



Процесс обучения нейросети



Выбираем сверточную нейросеть, т.к. исследуем лок во времени вообще, она инвар. к сдвигам, точнее рекуррентных.




Метод	SNR дых (dB)	Корр. дых	MSE дых	SNR пульс (dB)	Корр. пульс	MSE пульс	Время (сек)
Фильтры	100.00			5.74	0.879	0.2665	0.007
Вейвлеты	11.94	0.971	0.0639	5.31	0.877	0.2944	0.008
Нейросеть	37.69	1.000	0.0002	31.32	1.000	0.0007	857.593

$SNR = 10 \lg \left(\frac{N_{sig}}{N_{noise}} \right)$ - знак опр. какой метод здесь лучше


$Corr = cov(x,y) / (\sigma_x \cdot \sigma_y)$ - какой метод сохр. форму сигнала

$MSE = \sqrt{\sum (пр.-исл.)^2}$ - какой метод точнее по амплитуде

Спектр дыхания (0-1 Гц)



Спектр пульса (0.5-3 Гц)



Вывод : Для дыхания лучше подойдет линейный фильтр
 Для пульса — нейросеть.